

# Laporan Analisis CNN Dengan Dataset CIFAR10

## A. Pendahuluan

Dalam ranah klasifikasi citra, penggunaan model Convolutional Neural Network (CNN) telah menjadi salah satu metode yang sangat efektif. CNN menawarkan kemampuan untuk mengekstraksi fitur dari gambar secara hierarkis, membuatnya sangat cocok untuk tugas-tugas yang melibatkan data gambar kompleks seperti dataset CIFAR-10. Melalui pemanfaatan CNN, eksperimen ini bertujuan untuk mengevaluasi pengaruh berbagai parameter arsitektur dan pelatihan terhadap performa model.

Dataset CIFAR-10 merupakan kumpulan data gambar berwarna dengan 10 kelas, seperti pesawat, mobil, burung, dan sebagainya. Gambar-gambar ini memiliki resolusi 32x32 piksel dan mengandung tiga saluran warna (RGB). Penelitian ini menggunakan transformasi tertentu, seperti normalisasi, untuk memastikan distribusi data yang optimal sebelum pelatihan model. Eksperimen melibatkan beberapa konfigurasi, termasuk ukuran kernel, jenis pooling, metode optimasi, dan jumlah epoch, untuk memahami dampaknya terhadap akurasi dan generalisasi model. Selain itu, diterapkan teknik early stopping untuk mengurangi risiko overfitting.

## B. Deskripsi Dataset

Dataset CIFAR-10 terdiri dari koleksi gambar berwarna dengan resolusi 32x32 piksel yang mencakup sepuluh kelas objek, seperti hewan dan kendaraan. Dataset ini terbagi menjadi dua bagian utama: data pelatihan yang terdiri dari 50.000 gambar dan data pengujian sebanyak 10.000 gambar. Untuk memastikan data siap digunakan dalam pelatihan model CNN, setiap gambar dikonversi menjadi tensor, format data yang kompatibel dengan PyTorch. Selanjutnya, dilakukan normalisasi nilai piksel dengan rata-rata (0.4914, 0.4822, 0.4465) dan standar deviasi (0.2023, 0.1994, 0.2010) untuk setiap saluran warna. Normalisasi ini bertujuan untuk mengurangi perbedaan skala antar piksel, sehingga mempercepat konvergensi model selama pelatihan.

## C. Model Arsitektur CNN

Model CNN dirancang untuk mengekstraksi fitur dari gambar CIFAR-10 melalui kombinasi lapisan convolusi dan pooling. Spesifikasi model meliputi:

- Lapisan Convolusi:
  - Lapisan pertama: Kernel size bervariasi (3 atau 5), 32 filter, padding sesuai kernel size.
  - Lapisan kedua: Kernel size bervariasi (3 atau 5), 64 filter, padding sesuai kernel size.
- Lapisan Pooling: Jenis pooling (MaxPooling atau AveragePooling) diterapkan setelah setiap lapisan convolusi.
- Lapisan Fully Connected:
  - FC1: 128 unit.
  - FC2: 10 unit (output) untuk klasifikasi.
- Aktivasi: Fungsi ReLU digunakan pada setiap lapisan convolusi dan fully connected.
- Output: Log Softmax untuk klasifikasi multi-kelas.

#### **D. Early Stopping**

Strategi early stopping diterapkan untuk menghentikan proses pelatihan sebelum mencapai jumlah epoch maksimum jika akurasi pada data pengujian tidak meningkat dalam lima epoch berturut-turut. Pendekatan ini bertujuan untuk menghindari overfitting dan mengurangi waktu pelatihan yang tidak diperlukan.

#### **E. Parameter yang Diuji**

Berbagai kombinasi parameter diuji untuk mengevaluasi performa model:

Ukuran Kernel:

- 3.
- 5

Jenis Pooling:

- MaxPooling.
- AveragePooling.

Metode Optimasi:

- SGD.
- RMSProp.
- Adam.

Jumlah Epoch:

- 5.
- 100.

#### **F. Hasil dan Analisis**

Hasil eksperimen dapat dilihat pada grafik yang menunjukkan dinamika metrik pelatihan untuk setiap kombinasi parameter. Grafik tersebut menunjukkan bahwa penurunan train loss mengindikasikan model dapat belajar dengan baik dari data pelatihan. Sementara itu, kestabilan test loss yang diikuti dengan peningkatan akurasi menandakan bahwa model berhasil melakukan generalisasi dengan baik pada data uji. Terlihat pula bahwa pelatihan sering kali berhenti sebelum mencapai jumlah epoch maksimum karena penerapan early stopping.

Beberapa hasil dan analisis yang dapat disimpulkan dari eksperimen ini adalah sebagai berikut:

- **Pengaruh Ukuran Kernel**  
Ukuran kernel 5 menghasilkan akurasi yang lebih tinggi dibandingkan ukuran kernel 3 pada sebagian besar kombinasi parameter. Hal ini menunjukkan bahwa ukuran kernel yang lebih besar dapat memberikan performa yang lebih baik dalam ekstraksi fitur.
- **Pengaruh Jenis Pooling**  
Metode MaxPooling cenderung memberikan hasil yang lebih baik dibandingkan dengan AveragePooling, menunjukkan bahwa pemilihan jenis pooling mempengaruhi kualitas generalisasi model.
- **Pengaruh Optimizer**  
Optimizer Adam menunjukkan konvergensi yang lebih cepat dan performa yang lebih

baik, sementara SGD memberikan hasil yang stabil meskipun memerlukan lebih banyak epoch untuk mencapai hasil yang optimal.

- Jumlah Epoch

Dengan pelatihan 100 epoch, model memiliki kesempatan untuk mengeksplorasi performa optimal. Meskipun demikian, penerapan early stopping sering kali menghentikan pelatihan lebih awal, mengindikasikan bahwa model dapat mencapai konvergensi lebih cepat sebelum jumlah epoch maksimum tercapai.

#### G. Kesimpulan

Berdasarkan hasil eksperimen, kombinasi parameter terbaik yang menghasilkan performa optimal adalah sebagai berikut: penggunaan kernel size 5, metode pooling MaxPooling, optimizer Adam, dan jumlah epoch sebanyak 100 dengan penerapan early stopping yang efektif. Teknik early stopping terbukti sangat berguna dalam mencegah overfitting serta mempercepat proses pelatihan dengan menghentikan pelatihan lebih awal setelah model mencapai konvergensi yang memadai. Selain itu, penggunaan scheduler juga memberikan kontribusi positif dalam mengoptimalkan proses pelatihan, memastikan model tetap terlatih dengan efisien tanpa melibatkan waktu yang berlebihan.